

Data Clustering Task Report

목차:

1. 서론

2. EDA

2.5. 기존 주제의 문제점

3. K-Means

4. DBSCAN

5. Hierarchical Clustering

6. 결론

1. 서론

UR3 Cobotops 데이터셋의 센서 데이터를 활용하여 작업 조건에 따른 데이터의 군집 구조를 분석한다.

K-Means, DBSCAN, Hierarchical Clustering을 적용하여 데이터가 자연스럽게 어떠한 그룹으로 분리되는지 확인하고, 군집별 특성을 분석한다.


기존의 주제는 Tool Current와 다른 피처들이 물건 하중을 군집할 수 있는지 확인하는 것이었으나 치명적인 문제점이 발견하여 아래에 기술한다.

여러 센서 피처를 활용하여 데이터의 잠재적인 군집 구조를 탐색하고, 군집이 로봇의 운영 상태를 어떻게 나누는지 확인한다.

모든 과정은 **Standard Scaling**을 진행한다.

2. EDA

이 데이터셋을 모은 논문([1] M. Tyrovolas, C. Stylios, K. Aliev, and D. Antonelli, "Leveraging Information Flow-Based Fuzzy Cognitive Maps for Interpretable Fault Diagnosis in Industrial Robotics," in Technological Innovation for Human-Centric Systems, L. M. Camarinha-Matos and F. Ferrada, Eds. Cham, Switzerland: Springer, 2024, pp. 98–110.)을 보면, 이 UR3 Cobotops dataset을 만든 정확한 과정은 다음과 같다.



로봇에게 A에서 B로 물건을 옮기는 작업을 시키며 3가지 조건을 변경했다.

첫번째로, 적재 하중을 1kg, 2kg, 3kg.

두번째로, 이동 속도를 60%, 80%, 100% (최고 210 rad/s 기준).

세번째로, 파지력 (악력)을 80N, 100N, 120N.


으로 총 27개의 조합을 각 조건마다 25번씩 반복하며 125 Hz로 1초에 125번씩 수집하였다.

#	Column	Non-Null Count	Dtype
0	Num	7409 non-null	int64
1	Timestamp	7409 non-null	str
2	Current_J0	7363 non-null	float64
3	Temperature_J0	7355 non-null	float64
4	Current_J1	7355 non-null	float64
5	Temperature_J1	7355 non-null	float64
6	Current_J2	7355 non-null	float64
7	Temperature_J2	7355 non-null	float64
8	Current_J3	7355 non-null	float64
9	Temperature_J3	7355 non-null	float64
10	Current_J4	7355 non-null	float64
11	Temperature_J4	7355 non-null	float64
12	Current_J5	7355 non-null	float64
13	Temperature_J5	7355 non-null	float64
14	Speed_J0	7355 non-null	float64
15	Speed_J1	7355 non-null	float64
16	Speed_J2	7355 non-null	float64
17	Speed_J3	7355 non-null	float64
18	Speed_J4	7355 non-null	float64
19	Speed_J5	7355 non-null	float64
20	Tool_current	7355 non-null	float64
21	cycle	7409 non-null	int64
22	Robot_ProtectiveStop	7355 non-null	object
23	grip_lost	7409 non-null	bool

데이터셋의 모든 피쳐들이다.


6개 관절의 전류, 온도, 속도 데이터와 그리퍼의 전류가 있다.

이 피쳐들과 파생 변수들이 어떻게 로봇의 운영 상태를 군집화 할 수 있는지 알아보는것이 목표이다.




19개 피처의 선형적인 관계를 나타내는 히트맵을 보면, **Current J0**와 **Current J4**가 0.-758로 강한 역 상관관계를 보인다. **Speed J3**와 **Speed J5** 또한 강한 역 상관관계를 보인다.

모든 관절의 온도는 서로 0.99~1 사이의 매우 강한 상관관계를 보인다.



피쳐 분포 시각화 그래프를 보면 전류는 6개 관절 전류가 각각 다른 분포 형태를 가지고 각 변수가 서로 다른 정보를 담고 있을 가능성이 높다. 속도는 6개 관절 전부 0에 몰려있으니 변별력이 제한적이다. 온도는 상관계수가 매우 높았던 것처럼 사실상 온도 하나의 변수를 6번 측정한 것과 같다.




첫번째는 전류와 속도만으로 PCA를 한 것이고 두번째는 온도를 추가한 PCA 투영 산점도 그래프이다.

첫번째 그래프에서 전류·속도 12개를 PCA로 2D 투영한 결과, 중앙에서 여러 방향으로 뻗어나가는 방사형 구조가 관찰되었다. 이는 데이터에 복수의 운영 상태 패턴이 혼재함을 시사하며, 클러스터링을 통해 이를 분리할 수 있는 근거가 된다.


두번째 그래프에서 추가로 온도 6개 변수를 포함하면 상관계수 0.99 이상의 중복 정보가 PC1을 지배하여 운영 상태 구조가 시각화에서 사라진다. 이는 온도 변수의 다중공선성이 분석에 미치는 부정적 영향을 보여주는 사례이기도 하다.

따라서, 원본 피쳐로 클러스터링을 진행 한 후, 클러스터 구조를 잘 보여주는 전류와 속도 PCA 그래프로 모델별 결과의 시각화를 진행한다.

2.5. 기존 주제의 문제점




가장 처음에 선택한 주제는 Tool Current를 비롯한 다양한 변수가 데이터셋이 수집될때의 물건 하중을 잘 군집화할 수 있는지 확인하는것이였다.



이 주제에는 큰 문제점들이 있었다. 첫번째는 Tool current = 하중의 정답이라는 가정 자체의 문제점인데 따른 논리는 데이터셋을 모을때 1kg, 2kg, 3kg로 실험했으니 Tool Current를

K-means로 나누니 3개의 봉우리가 나왔다고 이 봉우리 3개가 곧 1kg, 2kg, 3kg라고
생각했다. Tool current 1차원으로 K=3 클러스터링은 Silhouette 0.92가 나왔으나 애초에
삼봉분포이므로 너무 당연한 결과다.



Tool Current를 제외한 피처를 통해 클러스터링을 진행했으나, 정답을 Tool Current와
비교했다. 즉, 피처가 군집을 어떻게 나누었는지는 신경쓰지 않고 무조건 하중과 Tool
Current에 매몰되어 결과를 내었다.

데이터에 하중같은 라벨이 어디에도 없고 Tool Current의 결과를 보고 우리가 추정한것이지
확인된 사실이 아니다. 데이터셋이 모을때 하중 말고도 속도와 그리퍼의 힘을 다르게
실험하였다. 즉, 하중의 무게보다 Tool Current는 그리퍼의 힘을 대변하고 있을 가능성이 더
높았다.

따라서, 다양한 피처들로 로봇의 운영 상태를 클러스터링을 통해 발견하는 주제로
변경하였다.

3. K-Means

```

df = pd.read_csv("https://raw.githubusercontent.com/kzming2007/UR3_Cobot_ML/refs/heads/main/dataset/ur3_cobotops.csv")
df_clean = df.dropna().copy()

df_clean['ProtectiveStop_bool'] = df_clean['Robot_ProtectiveStop'].apply(
    lambda x: True if str(x).strip().lower() == 'true' else False
)

# 피쳐 그룹
current_cols = ['Current_J0', 'Current_J1', 'Current_J2',
                'Current_J3', 'Current_J4', 'Current_J5', 'Tool_current']
speed_cols = ['Speed_J0', 'Speed_J1', 'Speed_J2',
              'Speed_J3', 'Speed_J4', 'Speed_J5']
temp_cols = ['Temperature_T0', 'Temperature_J1', 'Temperature_J2',
             'Temperature_J3', 'Temperature_J4', 'Temperature_J5']

group_A = current_cols # 7개
group_B = current_cols + speed_cols # 13개
group_C = current_cols + speed_cols + temp_cols # 19개

groups = {
    'Group A (Current, 7)': group_A,
    'Group B (Current+Speed, 13)': group_B,
    'Group C (All, 19)': group_C
}

print(f"데이터: {len(df_clean)}행 x {len(df_clean.columns)}열")
for name, cols in groups.items():
    print(f" {name}: {cols}")

```

✓ 0.3s

19개의 센서 측정값으로 정의되는 로봇의 운영 상태는 몇 가지로 구분되는가를 확인하기 위해 단순히 모든 변수를 한 번에 넣고 돌리는 것을 지양하고, 로봇의 물리적 상태를 단계적으로 확장해 가며 어떤 정보가 군집화에 가장 핵심적인지 파악하기 위해 피쳐 그룹을 3단계로 설계했다.

Group A는 전기적 하중 상태 (**Current**, 7개 변수)로 로봇이 현재 얼마나 무거운 부하를 견디고 있는가를 파악하기 위해 각 관절의 전류와 그리퍼 전류로 구성했다.

Group B는 동적 운전 상태 (**Current + Speed**, 13개 변수)로 로봇이 움직이고 있는지, 정지해있는지의 동적 맥락을 추가하기 위해 속도 변수를 추가로 구성했다.

Group C는 종합 운영 상태로 19개 변수를 모두 사용했다. 가동 시간에 따른 열적 변화를 포함한 전체 센서 정보를 평가하기 위함이다.


```
scalers = {}
X_scaled = {}

for name, cols in groups.items():
    scaler = StandardScaler()
    X_scaled[name] = scaler.fit_transform(df_clean[cols].values)
    scalers[name] = scaler
    print(f"{name}: {X_scaled[name].shape}")


print("\n✅ StandardScaler 적용 완료")

✅ 0.0s

Group A (Current, 7): (7355, 7)
Group B (Current+Speed, 13): (7355, 13)
Group C (All, 19): (7355, 19)

✅ StandardScaler 적용 완료
```

모든 그룹의 변수들에 Standard Scaling을 적용했다.



Group A는 k가 4일때 실루엣 0.3814을 형성하고 5부터 점수가 하락한다. 비록 절대적인

실루엣 스코어가 높은건 아니지만 데이터가 4개의 상태로 자연스럽게 나뉘를 의미한다.

전류 변수만으로도 로봇의 운영 상태를 분류할 수 있는 가장 이상적인 조건이다.

Group B는 실루엣 점수 자체는 A와 크게 차이가 없지만 특정 k에서 뾰족한 피크를 만들지


못하고 k는 2부터 10까지 점수가 평탄하게 요동친다. 실루엣 스코어가 가장 높은 k인 10이

자동으로 선택되었으며 과적합 위험이 높다. 뒤이어 소개할 Group C도 k가 4에서 최적을

보였음으로 비교의 공정성을 위해 Group B도 k를 4로 고정하여 진행한다.

Group C는 가장 낮은 실루엣 점수인 0.3105를 기록했다. 서로 상관계수가 0.99인 온도 변수 6개가 추가되면서 k-means가 거리를 계산할때 불필요한 노이즈로 작용했다고 예상할 수 있다.

아래는 그룹 A의 결과다.



전체 데이터의 약 77%를 차지하는 Cluster 0이 중앙에 밀집되어있다.

나머지 다른 상태의 데이터들이 각기 다른축을 향해 뻗어가는 형태를 보이고있다.



이 히트맵은 피쳐들의 군집별 평균값을 보여주며, 각 군집이 어떤 상태인지를 구체적으로 설명한다.

클러스터 0은 77%로 모든 관절의 전류값과 tool current가 0 근처 또는 평균적인 수준이다.


로봇이 무리한 부하 없이 가장 일반적이고 정상적인 궤적으로 작업을 수행 중인 가동 상태를 대변한다고 보인다.

클러스터 1은 4%로 다른 관절 전류는 평이한 반면, 유독 Tool Current가 0.459로 4개 군집 중 가장 높게 나타난다. 로봇팔의 궤적 자체는 험난하지 않으나, 그리퍼가 무거운 물체를 파지하여 끝단에 높은 하중이 걸려있는 상태를 의미한다고 해석된다.

클러스터 2는 15.6%로 천장에 걸려있는 관절인 J0은 높지만 J1과 J2 관절은 음수 방향으로 치솟았다.

무거운 물체를 들고 팔을 멀리 뻗거나 중력을 강하게 거스르는 자세를 취해 관절 모터에 부하가 가해지는 상태로 보인다.

클러스터 3은 2.9%로 J0과 J1,J2가 강하게 역회전하고 동시에 J4 관절의 전류가 급격히 상승하는 독특한 패턴을 보인다. 이는 로봇의 몸통을 크게 틀면서 손목을 꺾는 등 특수하고 제한적인 궤적을 수행하는 상태로 해석된다.



이 그래프는 개별 데이터 포인트들이 자신이 속한 군집에 얼마나 잘 맞는지, 혹은 다른 군집에 잘못 할당되었을 가능성이 있는지를 보여준다. 붉은 점선은 전체 평균 실루엣 점수를 나타낸다.

클러스터 0은 전에도 확인했듯이 전체 데이터의 대다수를 차지하며 음수값을 가지는 데이터는 없다. 또한 대부분의 데이터가 전체 평균선을 크게 상회하는 점수를 기록하고있다.

즉, 정상 상태의 패턴이 매우 뚜렷하다는것을 증명한다.


클러스터 2는 데이터는 두번째로 많지만 모양이 좋지 못하다. 그래프 왼쪽으로 뻗족하게 튀어나온 음수 영역이 존재한다. 또한 전체 평균선에 미치지 못하는 데이터의 비율이 상당히 높다.

즉, 클러스터 2로 넘어가는 경계가 명확하지 않고 다소 모호함을 나타낸다.

로봇이 갑자기 과부하에 걸리는 것이 아니라, 부하가 점진적으로 증가하면서 정상과 비정상의 경계선상에 높은 데이터들이 다수 존재한다는 점을 시사한다.

클러스터 1과 3은 데이터 수는 적지만 평균선을 상회하는 데이터들이 다수 존재하며, 음수 비율은 상대적으로 적다. 비록 발생 빈도는 낮지만, 클러스터 1이나 클러스터 3은 그 자체로 상당히 독특한 패턴을 가지고 있어 다른 상태들과 비교적 잘 구분되고 있음을 보여준다.

아래는 그룹 B의 결과다.




전류와 속도를 사용한 그룹 B의 엘보우 그래프는 뚜렷하게 꺾이는 구간 없이 완만하게 하락한다. 실루엣 그래프는 특정 K값에서 피크를 형성하지 못하고 톱니바퀴처럼 크게

요동치며, **K=10**에서 최고점을 기록했다. 이는 데이터 내에 자연스럽게 명확한 군집의 수가 존재하지 않음을 의미한다.

k=10으로 군집화된 결과를 2차원 **PCA**로 투영해본 결과, **10**개의 군집이 마치 조각보처럼 잘게 쪼개져있으며, 특히 데이터가 가장 밀집된 중앙영역조차 여러개의 군집으로 무의미하게 분할되어 경계가 심하게 겹쳐있다.


이는 전형적인 과적합 현상으로 알고리즘이 기계적으로 가장 높은 값인 **10**을 선택했지만 **10**개로 나눈 군집은 해석이 불가능하다. 속도 변수들이 **0** 근처에 몰려있어 군집을 무의미하게 잘게 쪼갠 것으로 보인다.



k가 **10**인 실루엣 플롯을 보면, 클러스터 **1**군집 하나가 전체 데이터의 대부분을 차지하고 나머지 **9**개의 군집은 데이터 수가 매우 적고 얇은 띠 형태로 나타난다.

클러스터 **1**과 **2**정도를 제외한 거의 모든 소규모 군집에서 왼쪽으로 길게 뻗은 음수 영역이 관찰된다.

따라서, 그룹 A와의 공정한 비교를 위해, 그리고 해석가능한 물리적 상태를 도출하기 위해 그룹 B의 K를 4로 강제 고정하여 재평가를 한다.




클러스터를 4개로 나눈 결과 어지러운 형태가 사라지고, 중앙의 클러스터 2를 중심으로 3개의 뿔어나가는 가지 형태가 나타났다.

그룹 A에서 보았던 4가지 물리적 상태 구조를 되찾은 것으로, 속도 변수가 추가된 상태에서도 본질적인 4개의 운영 상태가 존재함을 확인할 수 있다.

실루엣 점수는 0.3577정도로 A보다 낮게 측정되었다.

전반적으로 그룹 A보다 잘 측정된 것으로 보이지만, 실루엣 스코어가 A에 비해 낮고, PCA의 정보 보존력이 그룹 A는 55.9%인 반면, B는 43.3% 정도로, A가 원본 데이터의 분산을 더 많이 보존하고있다. 즉, 눈으로 보는 2차원 산점도가 실제 다차원 구조를 더 신뢰성 있게 반영하고 있는것은 그룹 A이다.

속도를 추가했음에도 실루엣 스코어와 PCA의 설명력이 떨어졌다는것은 속도 변수가 로봇의 운영 상태를 구분하는데 유의미한 정보를 제공하기 보다는 오히려 군집의 경계를 흐리게 만드는 노이즈로 작용했음을 의미한다.




가장 정상 상태인 클러스터 2를 제외하고, 클러스터 0과 1의 군집 형태가 심하게 일그러져있다.

두 군집 모두 평균선을 넘는 데이터가 하나도 없으며 절반에 가까운 데이터가 깊은 음수 영역으로 뻗어있다.

이는 클러스터 0과 1로 분류된 수많은 데이터들이 자신이 속한 군집보다 거대한 클러스터 2 군집에 수학적으로 더 가깝다는 것을 의미한다. 앞서, 전류 피처만 사용한 그룹 A 상태일때는 단 하나의 군집에서만 일부 음수가 발생했던 것과 대비된다.


대부분 0에 머물러 있는 속도 데이터라는 노이즈가 덮어씌워지면서 데이터간의 거리가 왜곡되고 군집 간의 경계가 붕괴된것으로 추측된다.

아래는 그룹 C의 결과다.



마찬가지로 k는 4에서 최고점을 찍었으나 그 점수가 세 그룹중 가장 낮다.

새로 추가된 온도 변수가 군집 형성에 도움을 주기보다는 심각한 방해물로 작용하고 있음을 수치로 입증할 수 있다.




온도 변수를 추가하니, Classification에서 보았던 두개의 거대한 기동 형태로 나뉘었다.

각 Centroids를 보면, 왼쪽은 클러스터 3가 전체를 차지하고, 오른쪽은 클러스터 2가 기동에 있고 1과 0은 위아래로 무의미하게 잘린듯 나뉘어있다.

원인을 분석하자면 온도 변수 6개는 서로 0.99 이상의 완벽한 상관관계를 가진다. 즉, 1개의 정보가 6번이나 중복되어 알고리즘에 투입된 상태라고 할 수 있다.

이 중복 정보가 거리 계산을 지배해 그래프의 x축이 사실상 온도를 대변하게 되면서 온도 상태로 분류해 버린 것으로 보인다.




실루엣 스코어를 보면, 클러스터 2와 3이 가장 많은 데이터를 가지고 있지만, 3에서 음수 부분이 보인다. 또한 클러스터 0은 평균선을 넘지 못하고 깊은 음수 영역으로 뻗어있다.


```
# 피쳐 그룹
current_cols = ['Current_J0', 'Current_J1', 'Current_J2',
               'Current_J3', 'Current_J4', 'Current_J5', 'Tool_current']
speed_cols   = ['Speed_J0', 'Speed_J1', 'Speed_J2',
               'Speed_J3', 'Speed_J4', 'Speed_J5']
temp_cols    = ['Temperature_T0', 'Temperature_J1', 'Temperature_J2',
               'Temperature_J3', 'Temperature_J4', 'Temperature_J5']
df_clean['Temperature_Mean'] = df_clean[temp_cols].mean(axis=1)

group_A = current_cols # 7개
group_B = current_cols + speed_cols # 13개
#group_C = current_cols + speed_cols + temp_cols # 19개
group_C = current_cols + speed_cols + ['Temperature_Mean'] # 14개
```

같은 정보가 6번 들어갔으므로, 만약 관절별 온도를 평균낸 단 하나의 온도값만 들어가면 어떻게 되는지 관찰하기 위해 추가적으로 실험해보았다.




가장 높은 실루엣 점수는 k가 6일때의 0.3336으로 나왔다. 이는 앞선 그룹 A, B와 비교하면 여전히 낮다.



가장 높은 K가 6일때와 4일때의 PCA 그래프를 보면 이전처럼 온도로 인해 데이터가 좌우 두 기둥으로 완전히 갈라지는 현상은 사라졌다.

데이터 차원의 왜곡을 방어했고 모델이 온도에 집착하지 않고 다시 물리적 가동 궤적을 바라보기 시작했다고 추측할 수 있다.



실루엣 플롯을 비교해보면 k가 6일때는 중심 군집을 제외한 다른 군집들의 데이터 절반 이상이 깊은 음수 영역으로 빠져있다.

데이터의 거시적 구조는 되찾았으나, 세밀한 군집의 경계는 붕괴됨을 알 수 있다.

온도는 전류나 속도처럼 상태에 따라 즉각적으로 변하는 값이 아니라, 로봇이 켜져있는 동안 서서히 오르고 내리는 연속적인 시계열 성향이 강하다.

따라서 평균을 내어 다중공산성을 제거했음에도 불구하고, 특정 운영상태를 나누는데 부적합한 노이즈임을 시사한다.

결론적으로, 불필요한 다중 공산성과 노이즈를 배제하고 로봇의 순수 물리적 부하량만을 대변하는 그룹 A가 이상 징후 포착 및 상태 분류를 위한 가장 정확한 데이터셋임을 시사한다.