

Data Clustering Task Report

목차:

1. 서론
2. EDA
3. K-Means
4. DBSCAN
5. Hierarchical Clustering
6. 결론

1. 서론

UR3 Cobotops 데이터셋의 센서 데이터를 활용하여 작업 조건에 따른 데이터의 군집 구조를 분석한다.

K-Means, DBSCAN, Hierarchical Clustering을 적용하여 데이터가 자연스럽게 어떠한 그룹으로 분리되는지 확인하고, 군집별 특성을 분석한다.

Tool Current를 비롯한 여러 센서 피처를 활용하여 데이터의 잠재적인 군집 구조를 탐색하고, 군집이 하중 상태(1kg, 2kg, 3kg)와 어떠한 관련성을 가지는지 분석한다.

모든 과정은 Standard Scaling을 진행한다.

2. EDA

#	Column	Non-Null Count	Dtype
0	Num	7409 non-null	int64
1	Timestamp	7409 non-null	str
2	Current_J0	7363 non-null	float64
3	Temperature_J0	7355 non-null	float64
4	Current_J1	7355 non-null	float64
5	Temperature_J1	7355 non-null	float64
6	Current_J2	7355 non-null	float64
7	Temperature_J2	7355 non-null	float64
8	Current_J3	7355 non-null	float64
9	Temperature_J3	7355 non-null	float64
10	Current_J4	7355 non-null	float64
11	Temperature_J4	7355 non-null	float64
12	Current_J5	7355 non-null	float64
13	Temperature_J5	7355 non-null	float64
14	Speed_J0	7355 non-null	float64
15	Speed_J1	7355 non-null	float64
16	Speed_J2	7355 non-null	float64
17	Speed_J3	7355 non-null	float64
18	Speed_J4	7355 non-null	float64
19	Speed_J5	7355 non-null	float64
20	Tool_current	7355 non-null	float64
21	cycle	7409 non-null	int64
22	Robot_ProtectiveStop	7355 non-null	object
23	grip_lost	7409 non-null	bool


결측치를 제거하고 난 후의 모든 피쳐들이다.

6개 관절의 **Current**, **Temperature**, **Speed**가 존재하고 그리퍼 전용인 **Tool Current**와 로봇의

이상 작동 여부를 나타내는 **Robot ProtectiveStop**과 **grip lost** 피쳐가 있다.

시계열을 나타내는 **Timestamp**와 **cycle** 피쳐가 있다. 이번 프로젝트에서는 시계열을

반영하지 않고 머신러닝하는 것이 목적임으로 배제한다.




Tool Current 분포를 확인한 결과, 삼봉 분포를 보였다. 특히 약 **0.08A, 0.18A, 0.49A**

부근에서 밀집 영역이 관찰되었으며, 이는 서로 다른 작업 상태 또는 부하 상태가 존재할 가능성을 시사한다.

따라서 세 개의 뚜렷한 밀집 구간은 서로 다른 작업 상태 또는 하중 상태를 반영할 가능성이 있으며, **K-Means**의 군집 수(**K**)를 결정할 때 **K=3**을 유력한 후보로 고려하였다.

Total Power Electric은 대부분 낮은 전력 영역에 분포하였으나 일부 데이터는 높은 전력 구간까지 긴 꼬리를 형성하였다.

이는 특정 작업 구간에서 순간적으로 높은 전력 소모가 발생했음을 의미하며, 군집 분석 시 고부하 상태를 구분하는 데 기여할 가능성이 있다.





Classification Task에서 RF 모델이 가장 중요하게 여긴 **Current J3**와 **J5**를 y로, 상봉 분포를 보인 **Tool Current**를 x로 두고 그래프를 그려보았다.

Tool Current와 **Current J3**의 관계를 시각화한 결과 **Tool Current**의 세 개 주요 구간에서 서로 다른 전류 분포가 관찰되었다. 이는 그리퍼의 전류 사용량이 로봇 관절의 부하 상태와 연관되어 있음을 시사한다.

Tool Current가 증가할수록 **J5** 전류 분포 역시 변화하는 경향이 나타났다. 특히 높은 **Tool Current** 영역에서 별도의 데이터 군집이 형성되어, 그리퍼 동작과 말단 관절의 움직임 사이에 연관성이 존재함을 확인하였다.

다음은 사용하는 피처를 2차원으로 **PCA**하여, 데이터 공간상에 자연스러운 군집이 존재하는지 전체적인 지형을 조망해본다.




첫번째 투영 산점도는 전류,속도,그리퍼 전류와 Classification Task에서 수행한 파생변수들만을 넣었을때의 결과다.

두번째 투영 산점도는 첫번째에다 온도 변수를 넣었을때의 결과다.

Classification Task에서 Random Forest Feature Importance 분석 결과, Temperature 계열 변수는 주요 예측 변수로 나타나지 않았다.

또한 EDA 과정에서 Temperature 변수는 Num, Cycle과 강한 상관관계를 보여 작업 시간의 영향을 크게 받는 것으로 확인되었다.

PCA 시각화에서도 Temperature를 포함할 경우 데이터가 특정 축 방향으로 과도하게 분리되는 현상이 나타났으며, 이는 작업 상태보다는 시간 경과에 따른 온도 상승 효과가 반영된 결과로 해석된다.



파생 변수들을 모두 제외하고 오직 원래의 **current, speed, tool current**만 넣고 투영 산점도를 그려봤을때, 오히려 **PC1**과 **PC2**가 설명하는 분산의 합이 **43.3% (24.3% + 19.0%)**로 이전(**38.4%**)보다 더 높아졌다. 만들어진 **Power, Total Power Electric** 파생변수는 사실 전류와 속도를 잘 조합해서 만든 값이다. 불필요한 중복 데이터가 사라지면서 데이터의 본질적인 구조가 더 깨끗하게 요약되고 있다고 추측된다.

따라서 본 **Clustering Task**에서는 실제 작업 상태를 반영하는 **Current, Speed, Tool Current**을 중심으로 군집화를 수행하였다.

3. K-Means

```

# 1차원이라도 StandardScaler를 적용하여 이후 단계(다차원 확장)와 동일한 파이프라인 유지
X_tool = df_clean[['Tool_current']].values
scaler = StandardScaler()
X_tool_scaled = scaler.fit_transform(X_tool)

# K = 2~10 범위에서 Inertia와 Silhouette Score 계산
K_range = range(2, 11)
inertias = []
silhouette_scores = []

for k in K_range:
    km = KMeans(n_clusters=k, n_init=10, random_state=42)
    labels = km.fit_predict(X_tool_scaled)
    inertias.append(km.inertia_)
    silhouette_scores.append(silhouette_score(X_tool_scaled, labels))

# 시각화: Elbow + Silhouette 그래프
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Elbow Method
axes[0].plot(K_range, inertias, 'bo-', linewidth=2, markersize=8)
axes[0].set_title('Elbow Method (Inertia)', fontsize=14, fontweight='bold')
axes[0].set_xlabel('Number of Clusters (K)')
axes[0].set_ylabel('Inertia (Within-Cluster Sum of Squares)')
axes[0].set_xticks(list(K_range))
axes[0].grid(True, linestyle=':', alpha=0.6)


# Silhouette Score
axes[1].plot(K_range, silhouette_scores, 'rs-', linewidth=2, markersize=8)
axes[1].set_title('Silhouette Score', fontsize=14, fontweight='bold')
axes[1].set_xlabel('Number of Clusters (K)')
axes[1].set_ylabel('Silhouette Score')
axes[1].set_xticks(list(K_range))
axes[1].grid(True, linestyle=':', alpha=0.6)

plt.tight_layout()
plt.show()

# 결과 요약 출력
print("\n[K값별 실루엣 점수]")
for k, s in zip(K_range, silhouette_scores):
    marker = " ◀ (삼봉 분포 기대)" if k == 3 else ""
    print(f" K={k:2d} → Silhouette = {s:.4f}{marker}")

```


우선, 삼봉분포를 가진 Tool Current 단일 피처로 학습시켜 보았다.



Elbow Method는 처음 예상했던대로 k가 3 일때에서 급격히 구부러진다.

k가 3일때의 실루엣 점수는 0.9248로 매우 높은 점수를 보여준다.

수학적으로 이 데이터는 3개의 그룹으로 나눌 때 응집도가 가장 좋을 것을 의미하며, 이는 실제 실험에서 세팅된 3가지 하중 조건(1kg, 2kg, 3kg)과 완벽하게 일치하는 결과이다.



밀도 그래프와 데이터 할당 산점도를 보면, 3개의 군집이 겹치는 구간이 단 하나도 없이 완벽하게 수직으로 분리된 것을 확인할 수 있다.

본 단일 변수 군집화 모델의 실루엣 점수는 **0.9248**로, 실제 산업 현장의 센서 데이터에서는 찾아보기 힘들 정도로 압도적인 군집화 성능을 보여주었다.

따라서 본 **Task**에서는 이 군집 결과를 하중 상태를 분류하는 이상적인 최대치로 설정한다.


향후 다른 로봇 관절 변수(속도, 관절 전류 등)들을 군집화에 추가할 경우, 로봇의 움직임에 의한 노이즈가 개입되어 이 **0.92**라는 완벽한 점수는 필연적으로 하락할 것이다. 그러나

이는 모델이 하중 외에 로봇의 역동적인 자세 변화까지 함께 학습하고 있다는 증거로 해석할 수 있다.

Tool Current 기반 군집화는 센서 자체에 포함된 하중 정보를 이용한 이상적인

기준(**Baseline**)으로 사용하였다. 이후 **Tool Current**를 제외한 상태에서 군집화를 수행하여,

다른 관절 센서만으로도 유사한 하중 상태를 구분할 수 있는지 평가하였다.



추가적으로 그린 이 투영 산점도는 **current**와 **speed**만을 넣고 그린 투영산점도이다. **tool**

current를 넣고 그린 투영 산점도와 한눈에 볼때 거의 달라지지 않았고 오히려 분산의 합이 더 늘었다.

```

df.columns = df.columns.str.strip()
df_clean = df.dropna().copy()

current_cols = [f'Current_J{i}' for i in range(6)]
speed_cols = [f'Speed_J{i}' for i in range(6)]

# 2. 군집화용 피쳐 설정
cluster_cols = current_cols + speed_cols
X_cluster = df_clean[cluster_cols]

# 3. 스케일링
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_cluster)

print(f"군집화에 사용된 피쳐 개수: {len(cluster_cols)}개")

```

✓ 0.0s

군집화에 사용된 피쳐 개수: 12개

Tool Current 단일 피쳐로 했을때, 값 크기로 군집이 나뉘는 결과는 사실 Tool Current가 정답이고 오름차순 정렬한것과 다른바가 없다.

따라서 Tool Current 없이 모델이 다른 관절들이 어떻게 움직이는지 전류, 속도, 필요하다면 온도나 파생 변수만 가지고 알아서 3개의 그룹으로 묶게 지정한뒤, Tool Current의 결과와 비교한다.

이를 통해 Tool Current가 아닌 다른 관절의 전류 및 속도 정보만으로도 하중 상태를 추론할 수 있는지 검증하고자 한다.

만약 군집 결과가 Tool Current 기반 군집과 유사한 구조를 보인다면, 로봇 전체 시스템의 움직임만으로도 현재 하중 상태를 간접적으로 추정할 수 있음을 의미한다.

Current와 speed의 12개 피쳐로만 학습했을때,

